

Бустинг

X - множество признаков, Y - множество классов. Пусть есть выборка $\{(x_i, y_i)\}_{i=1}^n \in X \times Y$, а также семейство *базовых алгоритмов* H , в котором каждый элемент $h(x; a) \in H$ определяется набором параметров $a \in A$.

Основная идея - построить новый алгоритм классификации в следующей форме:

$$F_M(x) = \sum_{m=1}^M h(x; a) b_m, \quad \text{где } a_i \in A, b_i \in \mathbb{R}$$

Построение проводится *жадно*: пусть уже есть классификатор F_{k-1} (от $k - 1$ параметра), тогда построение классификатора F_k сводится к подбору наиболее оптимальных параметров a_k, b_k :

$$F_k = F_{k-1} + h(\cdot, a_k) b_k$$

Подбор параметров

Оптимальность параметров определяются с помощью функции ошибки:

$$Q = \sum_{i=1}^N L(y_i, F(x_i)) \rightarrow \min, \quad \text{где } L(y_i, F(x_i)) - \text{функция потерь.}$$

Минимизируем функционал с помощью метода *градиентного спуска*. Пусть есть алгоритм F_{k-1} . Найдем такой $b_k \in \mathbb{R}$, что значение Q для $F_k = F_{k-1} - b_k \nabla Q$ минимально.

$$\begin{aligned} \text{Тут } \nabla Q &= \left[\frac{\partial Q}{\partial F_{k-1}}(x_i) \right]_{i=1}^N = \left[\frac{\partial L(y_i, F_{k-1})}{\partial F_{k-1}}(x_i) \right]_{i=1}^N \\ \text{То есть } b_k &= \underset{b \in \mathbb{R}}{\operatorname{argmin}} \left(\sum_{i=1}^N L(F_{k-1}(x_i) - b \nabla Q_i) \right) \end{aligned}$$

Однако ∇Q не является алгоритмом из H , поэтому найдем наиболее "близкий" алгоритм $h(\cdot, a_k)$:

$$a_k = \underset{a \in A}{\operatorname{argmin}} \left(\sum_{i=1}^N L(\nabla Q_i, h(x_i; a)) \right)$$

Это эквивалентно обучению базового алгоритма на выборке $\{(x_i, \nabla Q_i)\}_{i=1}^N$. Теперь осталось найти наиболее оптимальный b_k :

$$b_k = \underset{b \in \mathbb{R}}{\operatorname{argmin}} \left(\sum_{i=1}^N L(F_{k-1}(x_i) + h(x_i; a_k)b) \right)$$

Таким образом, $F_k = F_{k-1} + b_k h(\cdot; a_k)$

Бустинг над деревьями Рассмотрим случай бинарной классификации, когда в качестве базовых алгоритмов выступают решающие деревья. Каждому листу дерева соответствует значение a_i - "степень принадлежности" одному из классов. Множество X разбивается на J непересекающихся областей $R_{i=1}^J$, каждой из которых соответствует один лист дерева.

$$\text{Тогда } h(x, a) = \sum_{j=1}^J a_j I[x \in R_j]$$

Соответственно, $F_k = F_{k-1} + b_k \left(\sum_{j=1}^J a_j I[x \in R_j] \right) = F_{k-1} + \sum_{j=1}^J c_j I[x \in R_j]$, где $c_j = a_j b_j$. В таком случае, вместо того, чтобы сначала искать оптимальные a_i , а затем b_i , можно сразу искать оптимальные c_i :

$$c_{j_k} = \underset{c \in \mathbb{R}}{\operatorname{argmin}} \sum_{x_i \in R_j} L(F_{k-1}(x_i) + c)$$